



Regressione Logistica e SVM

Classificazione binaria applicata al riconoscimento di funghi velenosi

ALISIA SALLEMI & GIANLUCA CEREÀ

Dataset Analizzato





Struttura del dataset

21 variabili categoriche non ordinabili: descrivono le caratteristiche osservabili dei funghi (colore, forma del cappello, lamelle, habitat, ecc.) e il tipo di terreno in cui si trovano.

1 variabile target binaria: indica se un fungo è **velenoso** oppure **commestibile**.

 Dataset UCI Mushroom — archive.ics.uci.edu/dataset/73/mushroom

Distribuzione delle Variabili



Analisi esplorativa

Le distribuzioni rivelano pattern significativi:

- Alcune variabili hanno un valore dominante (es. **gill-spacing**)
- Altre mostrano distribuzioni ampie con più picchi (es. **gill-color**)
- La variabile **veil-type** è costante e quindi è stata rimossa
- La variabile **target** è bilanciata

Target

Missing Values

Su 22 variabili totali, solo **una presenta valori mancanti**: stalk-root con 2.480 valori nulli, pari al **30,5%** dei dati. Tutte le altre variabili sono complete.

21 variabili

Completamente prive di valori nulli

1 variabile critica

stalk-root: 2.480 valori mancanti
(30,5%)

Imputazione NA


La variabile stalk-root è stata imputata con la moda calcolata sul training set

Variabili dummy

One-hot encoding

- Le variabili categoriche non possono essere utilizzate direttamente da molti algoritmi di classificazione, che richiedono input numerici.
- Per questo vengono trasformate in **variabili dummy**, ovvero variabili binarie (0/1) che indicano la presenza o l'assenza di una determinata categoria.

gill-color	
brown	
white	
yellow	
black	
green	




gill-color brown		gill-color white		gill-color yellow		gill-color black		gill-color green	
1		0		0		0		0	
0		1		0		0		0	
0		0		1		0		0	
0		0		0		1		0	
0		0		0		0		1	

Regressione Logistica: Concetti

La regressione logistica è utilizzata per la **classificazione binaria**. I coefficienti stimati generano un punteggio continuo trasformato in probabilità tramite la funzione sigmoide:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$


$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Interpretazione della soglia:

- $\sigma(z) > 0,5 \Rightarrow$ classe 1 (velenoso)
- $\sigma(z) < 0,5 \Rightarrow$ classe 0 (commestibile)

Regressione Logistica: Risultati



Feature più influenti

spore-print-color_r ha l'odds ratio più alto: **138×** più probabilità di essere velenoso. Seguono odor_c (57×) e odor_f (39×).

Matrice di Confusione — Regressione Logistica

Interpretazione

Solo **3 falsi negativi** su 1.625 campioni: il modello ha classificato correttamente il **99,82%** dei funghi.

- **TP:** 842 — commestibili corretti
- **TN:** 780 — velenosi corretti
- **FP:** 0 — nessun falso allarme
- **FN:** 3 — velenosi mancati

	Predetto 0	Predetto 1
Reale 0	842	0
Reale 1	3	780

Accuracy

99,82%

Support Vector Machine

Obiettivo

Individuare l'iperpiano che **separa al meglio** le due classi (velenoso/comestibile) massimizzando il margine.

Support Vectors



I punti più vicini all'iperpiano: definiscono i margini di decisione del modello.

Soft Margin

Se i dati non sono separabili, si accettano alcuni errori per migliorare la generalizzazione.

Kernel Trick

Per separazioni non lineari, i dati vengono mappati in uno spazio a dimensione superiore.



Matrice di Confusione — Support Vector Machine

	Predetto 0	Predetto 1
Reale 0	842	0
Reale 1	2	781


Interpretazione

Solo **2 falsi negativi** su 1.625 campioni: il modello ha classificato correttamente il **99,88%** dei funghi.

- **TP:** 842 — commestibili corretti
- **TN:** 781 — velenosi corretti
- **FP:** 0 — nessun falso allarme
- **FN:** 2 — velenosi mancati

Accuracy

99,88%



Sviluppi Futuri

1 Fine Tuning degli Iperparametri

Ottimizzazione dei parametri di configurazione del modello.

```
penalty="l1", solver="liblinear", C=1.0
```

2 Cross Validation

Suddivide il dataset in più sottoinsiemi, addestrando e testando il modello su diverse combinazioni per ottenere prestazioni più robuste.

3 Riduzione della Dimensionalità

Dopo la creazione delle variabili dummy si possono utilizzare tecniche come PCA o Feature Selection per ridurre il numero di variabili mantenendo le informazioni più rilevanti.



Progetto disponibile su GitHub:

github.com/gianlucaaa00/logistic-regression